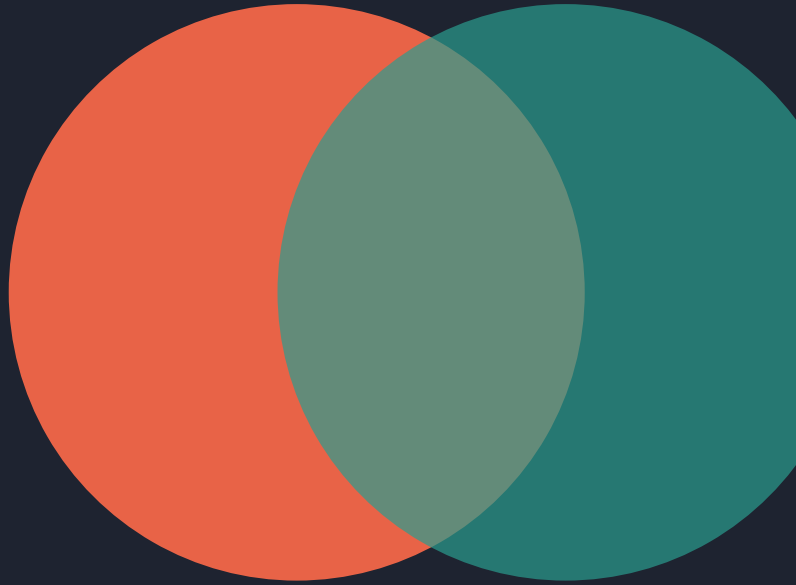
Hidden Pairs

От деревьев решений к SVM
на взвешенном PCA



0.9437
public ROC-AUC на Kaggle

Введение в машинное обучение · Kaggle Week 03 · сентябрь 2026

Задача

Каждая строка — пара скрытых наблюдений, описанная 512 анонимными числовыми признаками.

Нужно предсказать вероятность того, что оба наблюдения — одна и та же сущность.



→ **P(одна сущность)**
1 — одна, 0 — разные

Метрика: ROC-AUC — важен порядок скоров, а не их значения

2 520	**train** обучаем модели и весь препроцессинг
560	**validation** другие сущности — выбор модели
1 116	**test** только предсказания для Kaggle

Что показали данные

0.21

медианная |корреляция| признака с target (максимум 0.31)

0.70

ROC-AUC лучшего одиночного признака

0.16

средняя |корреляция| между признаками

323

компоненты PCA нужны для 90% дисперсии

Вывод

Сигнал есть в каждом признаке, но слабый.

Признаки почти независимы и не сжимаются в пару компонент.

Нужна модель, которая объединяет все 512 признаков сразу.

Хвостатые распределения: skew 2.2 → 1.1 после log1p

Что мы измеряли

1. **ROC-AUC**
   Вероятность, что настоящая пара получит скор выше ненастоящей. 0.5 — случайно, 1 — идеально.

2. **CV, 5 фолдов (OOF)**
   Каждая строка train предсказана моделью, которая её не видела. 2 520 строк — стабильная оценка.

3. **Validation**
   Другие сущности — проверка на новых объектах. 560 строк — шум около ±0.008.

4. **Train vs validation**
   Большой разрыв между ними — признак переобучения.

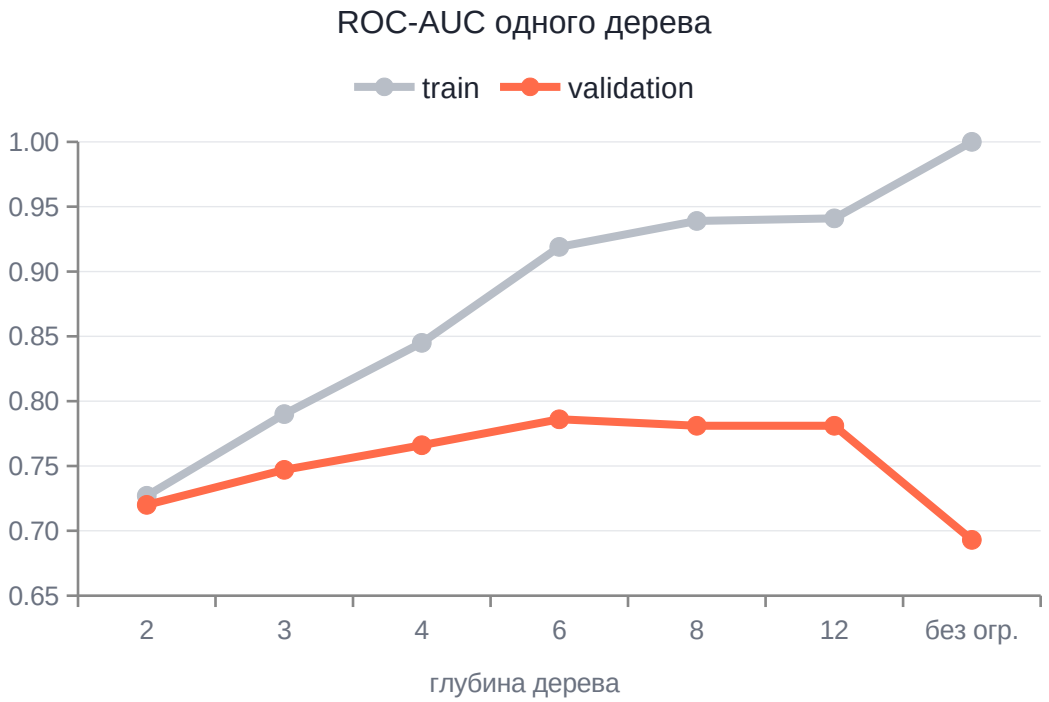
5. **Public leaderboard**
   Контроль на Kaggle. Модель по нему не выбирали.

Критерий выбора

(CV + valid) / 2

Модель должна быть хороша и на фолдах, и на новых сущностях — так мы меньше подгоняемся под 560 строк validation.

Шаг 1. Деревья решений



0.79

потолок одного дерева (глубина 6)

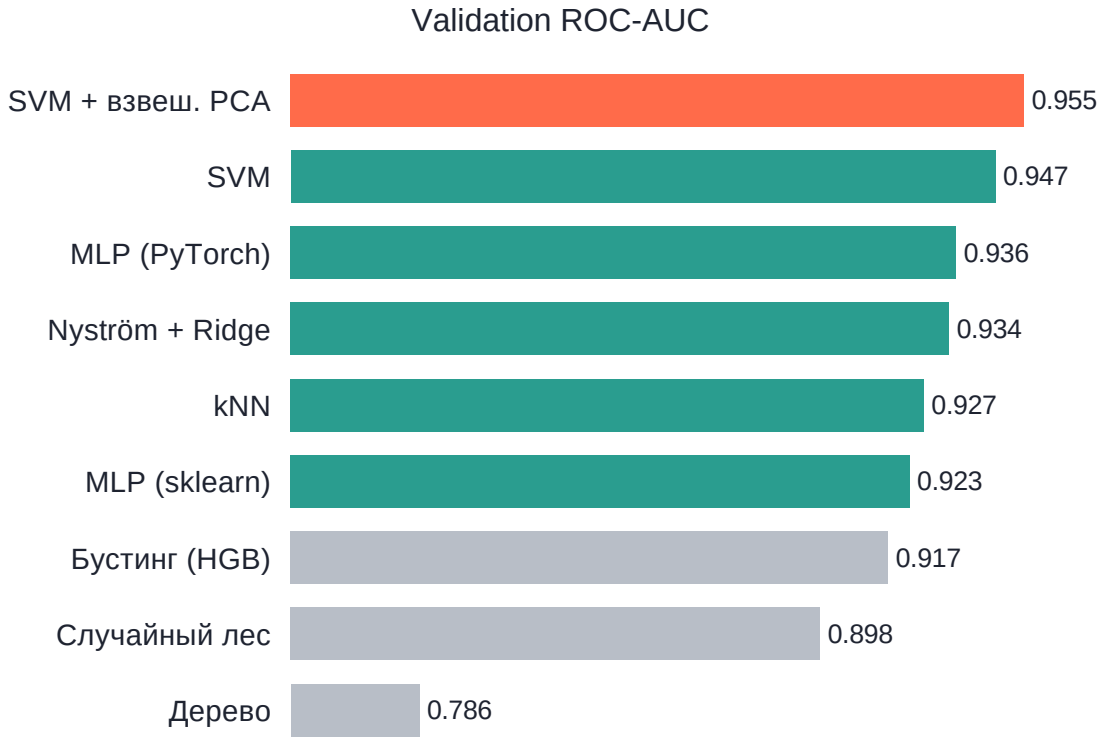
1.00 / 0.69

без ограничений: train / validation — переобучение

0.90 → 0.92

случайный лес → бустинг: лучше, но упёрлись

Шаг 2. Модели на расстояниях



Почему SVM

Дерево делит по одному признаку за раз, а сигнал размазан по всем 512.

RBF-ядро сравнивает объекты по расстоянию сразу во всех признаках.

Поэтому модели на расстояниях (SVM, kNN) обгоняют деревья.

деревья остальные

Подбор параметров: Optuna

1. **Триал 0**
   лучшие известные параметры — точка отсчёта

2. **Триалы 1…N**
   алгоритм TPE пробует новые параметры рядом с удачными

3. **Цель**
   (CV + valid) / 2 — не подгоняемся только под validation

SVM + взвеш. PCA **30 триалов**

Лучше не нашлось: подобранные вручную параметры уже у оптимума.

kNN **50 триалов**

k: 17 → 19, вес PCA: 0 → 0.07.

CV +0.002 и validation +0.002.

SVM на взвешенном PCA

РЕШЕНИЕ 1

1
log1p

сжимает длинные хвосты распределений

2
Масштаб
StandardScaler

все признаки в одном масштабе

3
PCA
464 из 512

убираем 48 хвостовых компонент (1.6% дисперсии)

4
× λ^0.1875
вес компонент

усиливаем главные направления

5
SVM (RBF)
C = 5, γ = 1/464

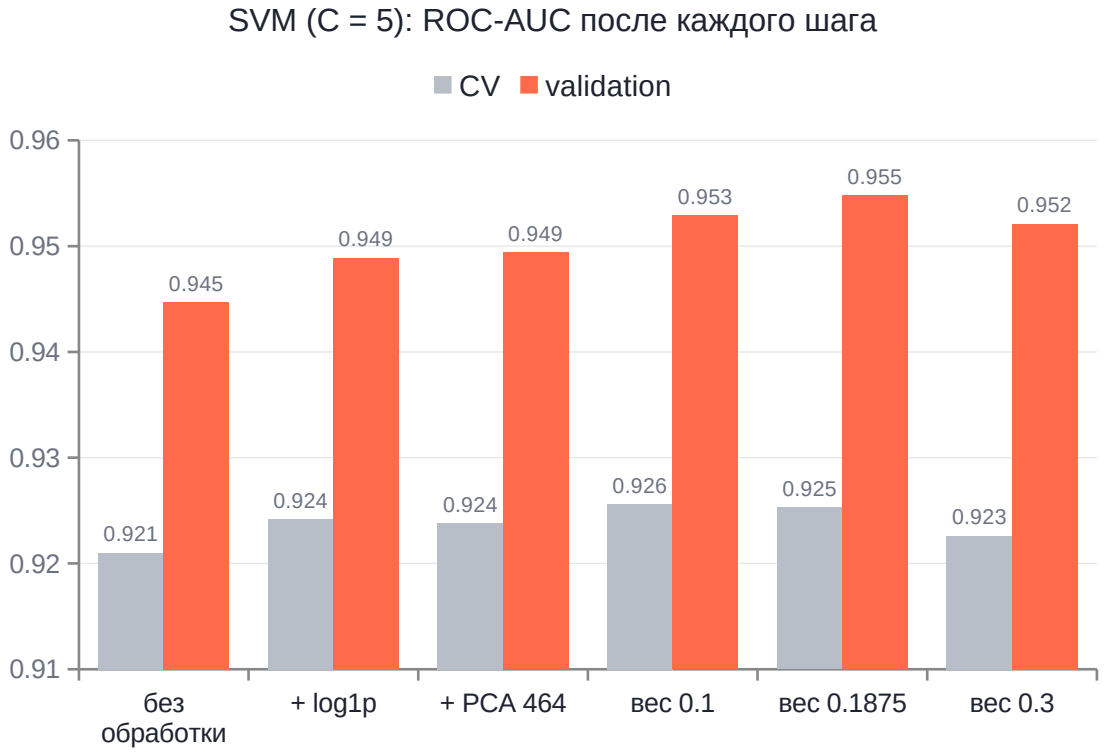
граница с максимальным зазором

0.9253	0.9548	0.9437
CV	Validation	Public LB

Всё внутри sklearn Pipeline: шаги обучаются только на train и заново на каждом фолде.

Что дал каждый шаг

РЕШЕНИЕ 1



≈ 400×

дисперсия 1-й компоненты больше, чем у 464-й: хвост — в основном шум

≈ 3×

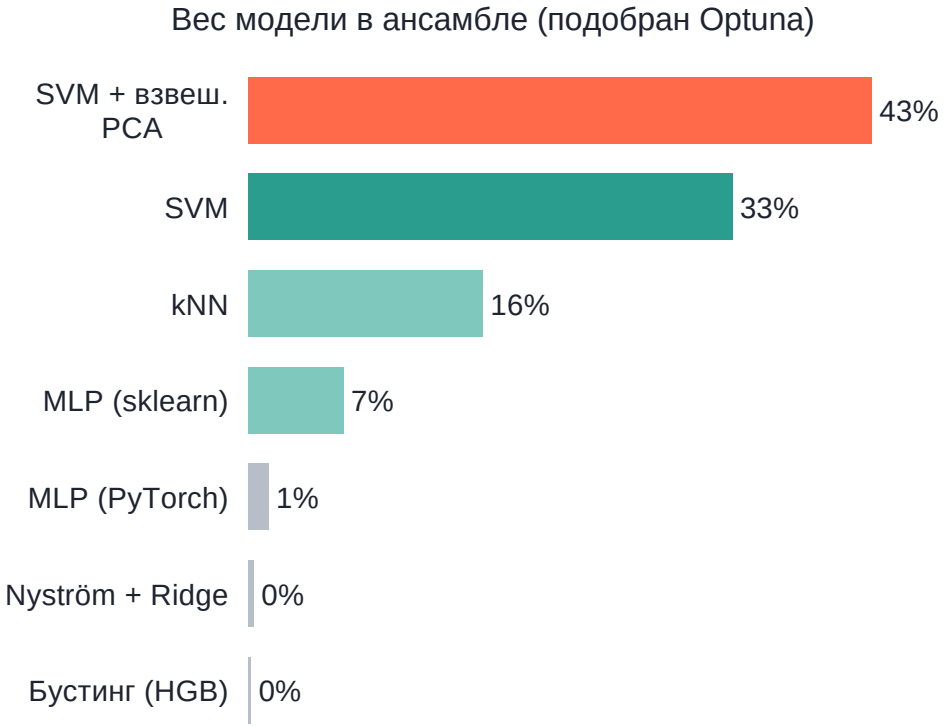
вес λ^0.1875 дополнительно усиливает главные компоненты относительно хвостовых

0.3

слишком сильный вес уже хуже: теряем полезные компоненты

Ансамбль: из чего он состоит

РЕШЕНИЕ 2



Основа · 76%

svm_w и SVM — самые точные модели. Они очень похожи (ρ = 0.99), но обычная SVM добавляет устойчивость на CV.

Разнообразие · 22%

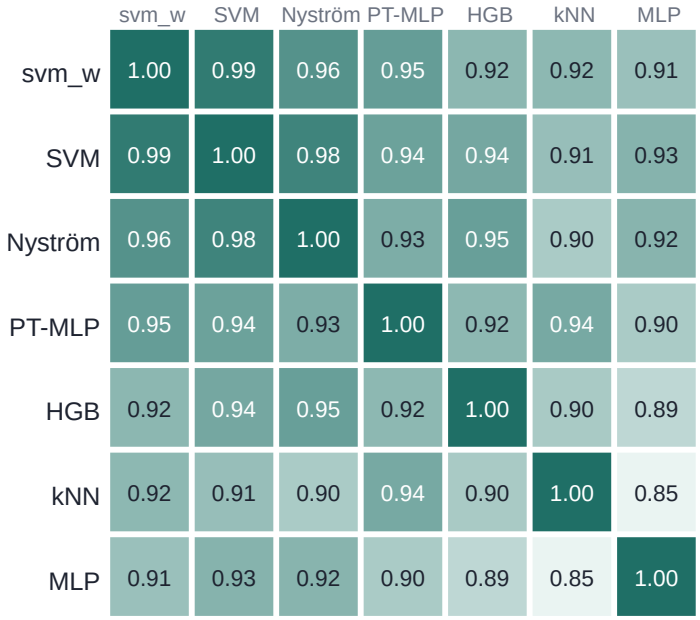
kNN и MLP слабее по отдельности, но меньше всего похожи на SVM (ρ ≈ 0.91–0.92) и исправляют другие ошибки.

≈ 0 · остальные

Nyström — приближение того же RBF-ядра, дубль SVM. Бустинг слабее. PyTorch MLP ничего нового не добавляет.

Ансамбль: почему такие веса

РЕШЕНИЕ 2



Ранговая корреляция (Спирмен) предсказаний на validation. Темнее — модели ранжируют пары почти одинаково.

Если убрать модель из ансамбля

svm_w	**−0.0043**	главный вклад
kNN	**−0.0010**	полезна, хотя слабее SVM
MLP	**−0.0005**	небольшой вклад
SVM	**+0.0006**	но CV падает на 0.0007
Остальные три	**0.0000**	Nyström, PT-MLP, HGB — без изменений

Δ validation ROC-AUC (было 0.9531)

Вес = качество × непохожесть. Копия SVM (Nyström, ρ = 0.98) получает ≈ 0, а более слабая, но другая kNN — 16%.

Сравнение двух решений

РЕШЕНИЕ 1

SVM на взвешенном PCA

log1p → PCA 464 → вес λ^0.1875 → RBF-SVM

0.9253	0.9548	0.9437
CV	Validation	Public LB

РЕШЕНИЕ 2

Взвешенный ансамбль

фактически 4 модели: svm_w 43% · SVM 33% · kNN 16% · MLP 7%

0.9285	0.9531	0.9432
CV	Validation	Public LB

Разница 0.002 на validation и 0.0005 на public — в пределах шума. Порядок на public совпал с validation.

Итог

Финальный сабмит — SVM на взвешенном PCA

Лучший результат
validation 0.955, public 0.944

Проще
одна модель вместо семи, в 5 раз быстрее ансамбля

Воспроизводимо
только train, фиксированные сиды, Restart → Run All ≈ 3 мин

Главные выводы

- Слабый сигнал во всех признаках → модели на расстояниях лучше деревьев
- log1p + PCA с весом компонент: 0.9447 → 0.9548 на validation
- Ансамбль чуть лучше на CV, чуть хуже на validation — выбрали более простую модель

